

# Metropolis-Hastings 算法的 理论与应用

## 2022 年概率基础课程期末报告

学号：2022103795

姓名：吕明倩

日期：2022 年 12 月 25 日

# 算法原理简介

## MCMC 方法介绍:

在贝叶斯统计中, 通常希望得到一些后验量, 这些后验量可以写成某函数  $f(x)$  关于  $\pi(x)$  的期望  $E_\pi f(X) = \int_X f(x)\pi(x)dx$ , 这里随机变量  $X$  具有密度函数  $\pi(x)$ , 如果密度函数为  $\pi(x)$  的随机数  $X_1, X_2, \dots, X_n$  很容易通过 *Monte Carlo* 方法产生, 则根据大数定律,  $E_\pi f(X)$  可以直接通过  $\hat{E}_\pi f(X) = \frac{1}{n} \sum_{i=1}^n f(X_i)$  估计得到。但在实际问题中, 后验分布  $\pi(x)$  往往是复杂的、高维的、非标准形式的分布, 难以直接抽样, 所以提出 *MCMC* 算法。

*Markov Chain Monte Carlo* 就是在贝叶斯理论框架下发展起来的蒙特卡罗采样方法。*MCMC* 算法的基本思想是通过构建一个平稳分布为  $\pi(x)$  的 *Markov* 链  $X^{(1)}, X^{(2)}, \dots, X^{(n)}$ , 在一定的条件下可得:

$$\hat{E}_\pi f = \frac{1}{n} \sum_{i=1}^n f(X^{(i)}) \xrightarrow{P} E_\pi f = \int_X f(x)\pi(x)dx$$

## Metropolis-Hastings 方法:

对于 MH 算法可以采用以下步骤获得来自后验分布  $\pi(\theta)$  的样本:

- 确定一个初始值  $\theta_0$
- 从提案分布  $g(\cdot|\theta)$  中生成新候选值  $\theta^*$
- 计算 *M-H* 比率  $R(\theta, \theta^*) = \frac{\pi(\theta^*)g(\theta|\theta^*)}{\pi(\theta)g(\theta^*|\theta)}$ , 接受概率  $\alpha(\theta, \theta^*) = \min\{R(\theta, \theta^*), 1\}$
- 产生随机数  $u \sim U(0, 1)$ , 令

$$\theta^{(t+1)} = \begin{cases} \theta^*, & u \leq \alpha(\theta, \theta^*) \\ \theta^{(t)}, & u > \alpha(\theta, \theta^*) \end{cases}$$

- 重复步骤 2 至 4 得到采样序列  $\theta^{(1)}, \dots, \theta^{(n)}$ , 该序列可以看作来自后验分布  $\pi(\theta)$  的样本。

## Problem1

证明：M-H 算法最终是从函数  $\pi(\theta)$  中提取样本。将采样序列看作一个 Markov 链，则问题转化为证明  $\pi(\theta)$  是 Markov 链  $\{\theta^{(t)}\}$  的平稳分布。可以证明 Markov 链  $\{\theta^{(t)}\}$  满足细致平衡条件 (Detailed Balance Condition):  $\pi(\theta_1)p(\theta_1, \theta_2) = \pi(\theta_2)p(\theta_2, \theta_1)$ 。

假设  $\theta^{(t)} = \theta_1$ ,  $\theta^{(t+1)} = \theta_2$ 。若  $\theta_2 = \theta_1$ , 即拒绝了新候选值,  $\theta^{(t+1)} = \theta^{(t)}$ , 则上式 (DBC) 显然成立; 若  $\theta_2 \neq \theta_1$ , 即接受了新候选值, 马氏链发生状态跳转, 此时转移概率:

$$\begin{aligned}
 p(\theta_1, \theta_2) &= P(\theta^{(t+1)} = \theta_2 | \theta^{(t)} = \theta_1) \\
 &= P(\theta^{(t+1)} = \theta_2, u \leq \alpha(\theta^{(t)}, \theta^{(t+1)}) | \theta^{(t)} = \theta_1) \\
 &= P(\theta^{(t+1)} = \theta_2 | \theta^{(t)} = \theta_1) P(u \leq \alpha(\theta^{(t)}, \theta^{(t+1)}) | \theta^{(t+1)} = \theta_2, \theta^{(t)} = \theta_1) \\
 &= g(\theta_2 | \theta_1) P(u \leq \alpha(\theta_1, \theta_2)) \\
 &= g(\theta_2 | \theta_1) \min\{\alpha(\theta_1, \theta_2), 1\} \\
 &= \min\{g(\theta_2 | \theta_1) \frac{\pi(\theta_2)g(\theta_1 | \theta_2)}{\pi(\theta_1)g(\theta_2 | \theta_1)}, g(\theta_2 | \theta_1) \frac{\pi(\theta_1)}{\pi(\theta_2)}\} \\
 &= \frac{\min\{\pi(\theta_1)g(\theta_2 | \theta_1), \pi(\theta_2)g(\theta_1 | \theta_2)\}}{\pi(\theta_1)}
 \end{aligned} \tag{1}$$

注意到转移概率矩阵不依赖时间  $t$ , 因此 Markov 链  $\{\theta^{(t)}\}$  是时间齐次的。同时根据对称性可得:  $p(\theta_2, \theta_1) = \frac{\min\{\pi(\theta_1)g(\theta_2 | \theta_1), \pi(\theta_2)g(\theta_1 | \theta_2)\}}{\pi(\theta_2)}$ 。因此,  $\pi(\theta_1)p(\theta_1, \theta_2) = \pi(\theta_2)p(\theta_2, \theta_1)$  满足细致平衡条件。

所以,  $\pi(\theta)$  是 Markov 链  $\{\theta^{(t)}\}$  的平稳分布, 并且当  $\{\theta^{(t)}\}$  满足非周期、不可约条件后,  $\{\theta^{(t)}\}$  有唯一的极限平稳分布  $\pi(\theta)$ 。

**遍历性定理:** 若  $\{\theta^{(t)}\}$  是非周期、不可约的 Markov 链, 并且存在唯一的平稳分布  $\pi(\theta)$ , 则  $\theta^{(t)} \xrightarrow{d} \pi(\theta)$ , 即  $\theta^{(t)}$  依分布收敛到  $\pi(\theta)$ 。

所以根据遍历性定理, 若  $E_\pi f(X)$  存在, 则状态空间平均期望可由时间上的平均期望近似, 即存在  $T > 0$ , 当  $t \geq T$  时,  $\theta^{(t)} \xrightarrow{d} \pi(\theta)$ , 因此,  $\frac{1}{L} \sum_{t=T}^{T+L} f(\theta^{(t)}) \xrightarrow{a.s.} E_\pi f(X)$ 。

此外, 若采用对称的提案分布, 例如  $g(\theta^* | \theta) = \frac{1}{\sqrt{2\pi}\psi} e^{-(\theta^* - \theta)^2 / 2\psi^2}$ , 此时  $g(\theta^* | \theta) = g(\theta | \theta^*)$ , 所以接受率可以化简为  $\alpha(\theta, \theta^*) = \min\{\frac{\pi(\theta^*)}{\pi(\theta)}, 1\}$ 。

## Problem2

### Part1

样本  $X = (x_1, \dots, x_n)$ ,  $x_i \sim N(\mu = 200, \phi = \frac{1}{2})$ , 其中  $\phi = \frac{1}{\sigma^2}$ , 先验分布  $p(\mu, \phi) \propto \frac{1}{\phi}$ , 后验分布  $p(\mu, \phi | X) \propto \phi^{n/2-1} \exp\left(-\frac{\phi}{2} \sum_{i=1}^n (x_i - \mu)^2\right)$ 。选择正态分布作为两个参数  $\mu, \phi$  的提案分布, 即  $\mu^* \sim N(\mu, 1)$ ,  $\phi^* \sim N(\phi, 0.1)$ , *Metropolis-Hastings* 抽样函数的伪代码如下所示:

---

#### 算法 1 *Metropolis-Hastings*

---

**Input:** 样本  $x$ , 上一次采样值  $\mu, \phi$

**Output:** 新采样值  $\mu^*, \phi^*$

```
1: function METROPOLIS( $x, \mu, \phi, n = 100$ )
2:    $\mu^* = \text{rnorm}(1, \mu, 1)$  //从提案分布  $N(\mu, 1)$  中抽取新候选值  $\mu^*$ 
3:    $R(\mu, \mu^*) = \frac{\exp\{-\frac{\phi}{2} \sum (x - \mu^*)^2\}}{\exp\{-\frac{\phi}{2} \sum (x - \mu)^2\}} * \frac{\text{dnorm}(\mu, \mu^*, 1)}{\text{dnorm}(\mu^*, \mu, 1)}$ 
4:   if  $\text{runif}(1) > R(\mu, \mu^*)$  then
5:      $\mu^* = \mu$ 
6:   end if
7:    $\phi^* = \text{rnorm}(1, \phi, 0.1)$  //从提案分布  $N(\phi, 0.1)$  中抽取新候选值  $\phi^*$ 
8:    $R(\phi, \phi^*) = (\frac{\phi^*}{\phi})^{(\frac{n}{2}-1)} \exp(-\frac{\phi^* - \phi}{2} \sum (x - \mu^*)^2) * \frac{\text{dnorm}(\phi, \phi^*, 0.1)}{\text{dnorm}(\phi^*, \phi, 0.1)}$ 
9:   if  $\text{runif}(1) > R(\phi, \phi^*)$  then
10:     $\phi^* = \phi$ 
11:  end if
12: end function
```

---

通过循环调用函数 *metropolis* 可以获得参数  $\mu, \phi$  的采样序列。

---

#### 采样 2 *Metropolis-Hastings*

---

```
1:  $\text{para} = \text{matrix}(0, N, 2)$  //para 存放每次采样结果
2:  $\text{para}(1, :) = c(\mu_0, \phi_0)$ 
3: for  $i$  in  $2:N$  do
4:    $\text{para}(i, :) = \text{metropolis}(x, \text{para}(i-1, 1), \text{para}(i-1, 2))$ 
5: end for
```

---

关于 *Metropolis-Hastings* 算法, 提案分布的选取对于抽样结果至关重要, 选择一个适合的提案分布可以使 *Markov* 链在短时间内达到平稳分布, 但如果选择的提案分布欠佳, *Markov* 链恐难以收敛。

*Gibbs* 抽样是一种单元素 *Metropolis-Hastings* 算法的特殊情况, 当参数的满条件分布具有显式形式时, 可以直接从满条件分布中获得参数的采样序列。对于 *Problem2* 中的后验分布, 可以求得各参数的显式满条件分布, 考虑采用 *Metropolis-Hastings-Gibbs* 算法

实现采样，伪代码如算法 3 所示。其中，参数  $\mu, \phi$  的满条件分布依次为：

$$\mu^* \sim N\left(\frac{\sum x}{n}, \frac{1}{\sqrt{n\phi}}\right), \quad \phi^* \sim Ga\left(\frac{n}{2}, \frac{\sum (x - \mu)^2}{2}\right)$$

---

**算法 3** *Metropolis-Hastings-Gibbs*

---

```

1: //从满条件分布中直接抽样
2: for i in 2:N do
3:   para(i, 1) = rnorm(1,  $\frac{\sum x}{n}$ ,  $\frac{1}{\sqrt{n*para(i-1,2)}}$ )
4:   para(i, 2) = rgamma(1,  $\frac{n}{2}$ ,  $\frac{\sum (x - para(i,1))^2}{2}$ )
5: end for

```

---

## Part2

初始化  $\mu_0 = 0$  和  $\phi_0 = 5$ ，采集样本总数  $N = 3000$ ，预烧值  $m = 500$ 。

首先运用 *Metropolis-Hastings* 算法采样，获得参数  $\mu$  的完整轨迹以及预烧后轨迹（图 1），参数  $\phi$  的完整轨迹以及预烧后轨迹（图 2）。




图 1: MH 完整（左）和预烧后（右）的  $\mu$  的采样轨迹图




图 2: MH 完整（左）和预烧后（右）的  $\phi$  的采样轨迹图

可以观察到，当预烧 500 次后，参数  $\mu$  和  $\phi$  的 *Markov* 链收敛到平稳分布，此时预烧后参数的边缘分布直方图如图 3 显示，参数  $\mu$  和  $\phi$  的采样均值分别为 199.782 和 0.498，候选值的接受率分别为 0.255 和 0.541。




图 3: MH 预烧后参数的边缘分布直方图 (左:  $\mu$ , 右:  $\phi$ )

其次考虑运用 *Metropolis-Hastings-Gibbs* 算法采样, 获得参数  $\mu$  的完整轨迹以及预烧后轨迹 (图 4), 参数  $\phi$  的完整轨迹以及预烧后轨迹 (图 5)。




图 4: MHG 完整 (左) 和预烧后 (右) 的  $\mu$  的采样轨迹图




图 5: MHG 完整 (左) 和预烧后 (右) 的  $\phi$  的采样轨迹图

与 *Metropolis-Hastings* 算法相比, *Metropolis-Hastings-Gibbs* 算法每一步都会更新采样值, 可以更快达到平稳分布, 此时预烧后参数的边缘分布直方图如图 6 显示, 参数  $\mu$  和  $\phi$  的采样均值分别为 199.777 和 0.496。




图 6: MHG 预烧后参数的边缘分布直方图 (左:  $\mu$ , 右:  $\phi$ )

## R 语言代码

```
N = 3000 #总抽样次数
n = 100 #样本个数
set.seed(1234)
x = rnorm(n, 200, sqrt(2)) #从给定分布中抽取100个样本

#初始值
mu0 = 0
phi0 = 5

#输出结果
para = matrix(0,N,2)
para[1, ]=c(mu0, phi0)

#Metropolis-Hastings算法
metropolis<-function(x,mu,phi,n=100){
  mustar = rnorm(1, mu, 1)
  rat = exp((-phi/2)*(n*(mustar^2-mu^2)-2*sum(x)*(mustar-mu))) *
        (dnorm(mu,mustar,1)/dnorm(mustar,mu,1))
  if (runif(1) > rat) mustar = mu
  phistar = rnorm(1, phi, 0.1)
  rat = ((phistar/phi)^(n/2-1)*exp((- (phistar-phi)/2)*sum((x-mustar)^2))) *
        (dnorm(phi,phistar,0.1)/dnorm(phistar,phi,0.1))
  if (runif(1) > rat) phistar = phi
  return (c(mustar,phistar))
}
for (i in 2:N){
  para[i, ] = metropolis(x,para[i-1,1],para[i-1,2])
}

#预烧次数
m = 500

#图形展示
plot(para[,1], type='l', xlab = NULL, ylab = "All tracks of mu")
plot(para[,1], type='l', xlim = c(580,2920), ylim = c(199,200.5),
      ylab = "Burn-in tracks of mu", xaxt = 'n')
axis(1,c(500,1000,1500,2000,2500,3000))
plot(para[,2], type='l', xlab = NULL, ylab = "All tracks of phi")
plot(para[,2], type='l', xlim = c(580,2920), ylim = c(0.2,0.8),
      ylab = "Burn-in tracks of phi", xaxt = 'n')
axis(1,c(500,1000,1500,2000,2500,3000))

hist(para[m:N,1], prob=TRUE, xlab = "mu")
hist(para[m:N,2], prob=TRUE, xlab = "phi")
acceptmu = length(unique(para[,1]))/N #mu的接受率=0.255
acceptphi = length(unique(para[,2]))/N #phi的接受率=0.541
mean(para[m:N,1]) #mu的采样均值=199.782
mean(para[m:N,2]) #phi的采样均值=0.498

#Metropolis-Hastings-Gibbs
for (i in 2:N){
  para[i,1] = rnorm(1, sum(x)/n, 1/sqrt(n*para[i-1,2]))
  para[i,2] = rgamma(1, n/2, sum((x-para[i,1])^2)/2)
}

#预烧次数
m = 10
```



```

#图形展示
plot(para[,1], type='l', xlab = NULL, ylab = "All tracks of mu")
plot(para[2:3000,1], type='l', xlim = c(80,2920), ylim = c(199,200.5),
      ylab = "Burn-in tracks of mu", xaxt = 'n')
axis(1,c(0,500,1000,1500,2000,2500,3000))
plot(para[,2], type='l', xlab = NULL, ylab = "All tracks of phi")
plot(para[2:3000,2], type='l', xlim = c(80,2920), ylim = c(0.2,0.8),
      ylab = "Burn-in tracks of phi", xaxt = 'n')
axis(1,c(0,500,1000,1500,2000,2500,3000))

hist(para[2:N,1], prob=TRUE, xlab = "mu")
hist(para[2:N,2], prob=TRUE, xlab = "phi")
mean(para[2:N,1]) #mu的采样均值=199.777
mean(para[2:N,2]) #phi的采样均值=0.496

```